

세그먼트마다 연령대 분포 파악하기

Recency, Frequency, Monetary 가중치를 각각 0.2, 0.4, 0.4로 설정하여 구한 RFM 고객 세그먼트를 바탕으로 세그먼트별 고객 특성과 소비 성향을 분석해 보겠습니다.

먼저 세그먼트별로 연령대 분포가 어떻게 다른지 확인해 볼까요? 각 세그먼트마다 연령대 분포를 파이 차트로 시각화하면 한눈에 파악이 될 텐데요. 이를 위해서는 고객 세그먼트와 연령대 두 요소를 기준으로 고객 수를 집계해야 합니다. 그러면 일단 `rfm_segment`와 `age_group` 두 컬럼에 대해 `groupby`를 해 줘야겠죠. 그다음

🔗 `size()` 함수를 사용하면 고객의 수를 얻을 수 있습니다.

```
groupby_rfm_segment_age_group = customer_df.groupby(['rfm_segment', 'age_group']).size()
groupby_rfm_segment_age_group
```


	rfm_segment	age_group	0
0	1	20대 이하	84
1	1	30대	231
2	1	40대	268
3	1	50대	135
4	1	60대 이상	84
5	2	20대 이하	46
6	2	30대	121
7	2	40대	169
8	2	50대	161
9	2	60대 이상	114
10	3	20대 이하	57
11	3	30대	146
12	3	40대	238
13	3	50대	189
14	3	60대 이상	162

고객의 수가 표시된 컬럼 이름이 그냥 0이라 써져 있어서 컬럼 이름을 `num_customers`라고 바꿔 볼게요. 데이터 전처리 과정에서 했던 `rename()` 함수를 사용합니다. `columns` 파라미터에 딕셔너리를 전달할 때, 키 값인 0에 따옴표가 붙지 않는다는 점을 주의해 주세요.

```
groupby_rfm_segment_age_group = groupby_rfm_segment_age_group.rename(columns={0: 'num_customers'})
```

이제 파이 차트를 그리면 됩니다. `for` 문을 이용해 고객 세그먼트를 순회할 건데요. 각 세그먼트에 해당하는 데이터를 불린 인덱싱으로 추출한 뒤, `num_customers` 컬럼을 `plot()` 함수로 시각화하겠습니다. 이번에는 `labels` 파라미터에 변수를 따로 만들어서 넣어 주지 않고 `age_group` 컬럼의 `unique` 값을 전달할게요.

```
for i_segment in range(1, num_grades + 1):
    age_group_dist = groupby_rfm_segment_age_group[
        groupby_rfm_segment_age_group['rfm_segment'] == i_segment
    ]
    age_group_dist['num_customers'].plot(
        kind='pie',
        autopct='%1f%%',
        labels=age_group_dist['age_group'].unique(),
        title=f'{i_segment}등급 세그먼트 연령대별 고객 분포',
        ylabel='',
    )
    plt.show()
```



1등급 세그먼트 고객에 비해 2등급과 3등급 세그먼트 고객은 30대 이하의 비중이 작습니다. 한편 2등급 세그먼트와 3등급 세그먼트는 각 연령대마다 비율이 2% 포인트 내외만 차이 날 정도로 연령대 분포가 비슷한 경향을 띠고 있습니다. 2등급보다 3등급 세그먼트에서 30대 이하 비중이 약간 더 작긴 하네요. 일반적으로 중장년층에 비해 청년층의 구매력이 더 떨어지기 때문에 이런 결과가 나온 것 같습니다. 매출 기여도가 높은 3등급 세그먼트에 집중하여 마케팅을 전개한다면 젊은 세대보다는 중장년층을 타겟으로 하는 게 효과가 더 클 가능성이 높겠어요.


세그먼트마다 가족 구성 분포 파악하기

연령대 분포를 파악했던 것과 같은 방식으로 고객 세그먼트마다 가족 구성이 어떻게 다른지 확인해 보겠습니다. 가족 구성과 관련된 컬럼은 혼인 상태를 나타내는 `marital_status`와 부양 자녀 수를 나타내는 `children`이 있습니다. 이 두 컬럼을 하나씩 살펴볼게요.

먼저 세그먼트마다 혼인 상태별로 고객 수가 어떻게 분포되어 있는지 보겠습니다. `rfm_segment`, `marital_status` 두 컬럼에 대해 `groupby`를 수행하고 `size()` 함수를 이어서 호출해 주면 되겠죠? `for` 문을 이용해 각 세그먼트마다 파이 차트를 그릴게요.

```
groupby_rfm_segment_marital = customer_df.groupby(['rfm_segment', 'marital_status']).size()
groupby_rfm_segment_marital = groupby_rfm_segment_marital.rename(columns={0: 'num_customer'})

for i_segment in range(1, num_grades + 1):
    marital_status_dist = groupby_rfm_segment_marital[
        groupby_rfm_segment_marital['rfm_segment'] == i_segment
    ]
    marital_status_dist['num_customers'].plot(
        kind='pie',
        autopct='%1f%%',
        labels=marital_status_dist['marital_status'].unique(),
        title=f'{i_segment}등급 세그먼트 혼인 상태별 고객 분포',
        ylabel='',
    )
plt.show()
```




혼인 상태의 분포는 세그먼트에 따라 큰 차이가 없네요. 모든 세그먼트에서 배우자와 함께 사는 고객의 비율이 65% 정도로 높게 나타나며, 그다음으로 미혼자 비율이 20% 내외인 걸 확인할 수 있습니다.

그럼 세그먼트마다 부양 자녀의 수는 어떻게 분포되어 있는지 살펴봅시다. 이번에는 `rfm_segment`, `children` 두 컬럼에 대해 `groupby`한 뒤 `size()` 함수를 호출해야겠네요. 이전과 마찬가지로 `for` 문을 통해 세그먼트를 순회하며 파이 차트를 그릴게요.

```
groupby_rfm_segment_children = customer_df.groupby(['rfm_segment', 'children']).size()
groupby_rfm_segment_children = groupby_rfm_segment_children.rename(columns={0: 'num_customer'})

for i_segment in range(1, num_grades + 1):
    children_dist = groupby_rfm_segment_children[
        groupby_rfm_segment_children['rfm_segment'] == i_segment
    ]
    children_dist['num_customers'].plot(
        kind='pie',
        autopct='%1f%%',
        labels=[f'{i}명' for i in children_dist['children'].unique()],
        title=f'{i_segment}등급 세그먼트 부양 자녀 수별 고객 분포',
        ylabel='',
    )
plt.show()
```



부양 자녀 수는 세그먼트별로 뚜렷한 차이를 보이고 있습니다. 1등급에서 3등급으로 올라갈수록 자녀가 없는 고객의 비중이 상당히 커지며, 자녀가 있는 고객의 비중은 자녀 수와 무관하게 모두 비중이 줄어들고 있어요. 3등급 세그먼트에는 무자녀 고객이 40%를 넘으니 이러한 특성을 마케팅 전략에 반영할 수도 있겠네요.

세그먼트마다 품목별 매출 기여도 파악하기

이번에는 고객 세그먼트마다 품목별 매출 기여도가 어떻게 분포되어 있는지 살펴봅시다. 먼저 `rfm_segment`를 기준으로 `groupby` 해 줘야겠죠. 그다음에는 품목별로 매출 합을 구해야 하니 `sum()` 함수를 호출하겠습니다.

```
groupby_rfm_segment = customer_df.groupby('rfm_segment').sum(numeric_only=True).reset_index()
```

파이 차트를 그리기 위해 `groupby` 결과로부터 세그먼트 등급과 품목별 매출이 담긴 데이터만 뽑아 보겠습니다. 먼저 타깃이 되는 컬럼 이름들을 리스트 변수로 만들어 줄게요. 당연히 `rfm_segment`는 포함되어야 할 테고 `amount_`로 시작하는 컬럼까지 고르면 되는데요. 지금은 품목별 매출만 필요하기 때문에 모든 품목의 매출을 합한 `amount_total` 컬럼은 제외하겠습니다.

일단 `list comprehension`을 통해 `amount_total`을 제외하고 이름이 `amount_`로 시작하는 컬럼 이름들의 리스트부터 만들어 봅시다. `for` 문으로 `groupby_rfm_segment.columns`를 순회하면서 조건에 부합하는 컬럼 이름을 그대로 리스트에 넣어 주면 됩니다. `List comprehension`에서는 `if` 문을 `for` 문 뒤에 써 주면 조건을 설정할 수 있어요. `startswith()` 함수를 통해 이름이 `amount_`로 시작하는지 판단하고 동시에 `amount_total`과 이름이 다른지도 체크하겠습니다. `List comprehension`으로 리스트를 만들고 나면 `append()` 함수를 이용해 `rfm_segment`까지 리스트에 추가해 줄게요. 이 리스트 변수의 이름은 `selected_columns`라고 하겠습니다.

```
selected_columns = []
for col in groupby_rfm_segment.columns:
    if col.startswith('amount_') and col != 'amount_total':
        selected_columns.append('rfm_segment')
selected_columns
```

```
['amount_alcohol',
 'amount_fruit',
 'amount_meat',
 'amount_fish',
 'amount_snack',
 'amount_general',
 'rfm_segment']
```


이 컬럼들에 해당하는 데이터만 떼서 `amount_sum_per_product`라는 변수에 넣어 줄게요. 그리고 `set_index()` 함수를 통해 `rfm_segment` 컬럼을 인덱스로 만들겠습니다.

```
amount_sum_per_product = groupby_rfm_segment[selected_columns]
amount_sum_per_product = amount_sum_per_product.set_index('rfm_segment')
amount_sum_per_product
```

rfm_segment	amount_alcohol	amount_fruit	amount_meat	amount_fish	amount_snack	amount_general
1	26176800	40898800	16566800	6091800	4165200	13079300
2	231699100	22376800	133016000	31823200	22217000	39907400
3	619748000	49019100	324294100	71113900	51381200	73303100

이번에도 역시 `for` 문을 이용해 고객 세그먼트를 순회하며 그래프를 그리겠습니다. 앞서 `rfm_segment` 컬럼을 인덱스로 바꿔 두었기 때문에 `loc`을 통해 각 세그먼트별 데이터에 접근할 수 있어요. `plot()` 함수로 그래프를 그려 봅시다. 파라미터 설정은 모두 익숙할 거예요. 품목 순서에 맞게 `labels`에 품목 이름을 잘 전달해 주면 그래프를 파악하기 더 쉽겠죠?

```
for i_segment in range(1, num_grades + 1):
    amount_sum_per_product.loc[i_segment].plot(
        kind='pie',
        autopct='%1.1f%%',
        labels=['주류', '과일', '육류', '수산물', '과자', '잡화'],
        title=f'{i_segment}등급 세그먼트 품목별 매출 기여도',
        ylabel='',
    )
plt.show()
```



모든 고객 세그먼트에서 공통적으로 주류 매출이 가장 높고 그다음으로 육류의 매출이 높네요. 주류는 세그먼트에 따라 뚜렷하게 매출 기여도가 달라지는 품목이기도 합니다. 1등급에서 3등급으로 갈수록 주류 매출의 비중이 높아지고 있어요. 잡화 또한 경향성이 뚜렷한데요, 주류와 반대로 1등급에서 3등급으로 갈수록 매출 기여도가 큰 폭으로 감소하고 있습니다. 한편 수산물, 과일, 과자 모두 1등급에서 3등급으로 갈수록 조금씩 비중이 줄어듭니다. 육류의 매출 기여도는 3등급보다 2등급에서 약간 높게 나타나는군요.

이렇게 고객 세그먼트마다 품목별로 매출 기여도가 달라지는 이유는 가족 구성과도 관련이 있을 듯합니다. 가족 구성 분석에 따르면 1등급에서 3등급으로 갈수록 혼인 상태에는 큰 변화가 없는데 자녀의 수는 줄어드는 경향이 있었죠. 그러니 주류 소비는 늘고 과일, 과자 등 간식이나 잡화(생필품) 소비가 줄어드는 경향이 나타날 수도 있겠습니다.

어쨌든 3등급 세그먼트는 주류와 육류의 매출 기여도를 합치면 거의 80%에 육박하네요. 따라서 이 두 품목을 중심으로 마케팅을 전개하면 효과가 좋을 것 같습니다. 상황에 따라 3등급 세그먼트의 잡화 매출 기여도를 끌어 올려야 한다면 그에 맞게 전략을 짤 수도 있고요.

세그먼트마다 프로모션 참여율 파악하기

마지막으로 고객 세그먼트마다 프로모션 참여율은 어땠는지 살펴봅시다. 프로모션 관련 컬럼을 보면 고객이 프로모션에 참여했을 시 1, 참여하지 않았을 시 0으로 표시되어 있는데요. 그렇기 때문에 `rfm_segment` 로 `groupby` 한 후 `mean()` 함수를 써 주면 자연스럽게 세그먼트마다 프로모션별 참여율을 구할 수 있습니다.

```
groupby_rfm_segment = customer_df.groupby(['rfm_segment']).mean(numeric_only=True).reset_index()
```

파이 차트를 그리기 위해 `groupby` 결과 데이터에서 세그먼트 등급과 프로모션별 참여율이 담긴 데이터만 뽑아 보겠습니다. 먼저 타깃이 되는 컬럼 이름들을 리스트 변수로 만들어 줄게요. `promotion_1` 부터 `promotion_6` 까지는 `list comprehension`으로 간단히 만들어 주고 여기에 `rfm_segment` 를 추가하겠습니다.

```
selected_columns = [f'promotion_{i}' for i in range(1, 7)]
selected_columns.append('rfm_segment')
selected_columns
```

```
['promotion_1',
 'promotion_2',
 'promotion_3',
 'promotion_4',
 'promotion_5',
 'promotion_6',
 'rfm_segment']
```


품목별 매출 기여도를 살펴볼 때처럼 타깃 컬럼의 데이터만 떼서 새로운 변수에 넣어 준 뒤, `set_index()` 함수를 통해 `rfm_segment` 컬럼을 인덱스로 만들겠습니다. 변수 이름은 `avg_promotion` 이라고 해 볼게요.


```
avg_promotion = groupby_rfm_segment[selected_columns]
avg_promotion = avg_promotion.set_index('rfm_segment')
avg_promotion
```

	promotion_1	promotion_2	promotion_3	promotion_4	promotion_5	promotion_6
rfm_segment						
1	0.000000	0.002494	0.071072	0.006234	0.001247	0.074813
2	0.050736	0.009820	0.072013	0.078560	0.060556	0.127660
3	0.140152	0.027778	0.078283	0.140152	0.155303	0.246212

세 가지 고객 세그먼트와 여섯 가지 프로모션에 대해 참여율을 한눈에 파악할 수 있는 그래프를 그리고 싶네요. 세로 방향 막대그래프를 그리되, X축이 고객 세그먼트를 나타내고 Y축에 참여율을 나타내면 좋을 것 같습니다. 여섯 가지 프로모션은 막대 색깔로 구분시키고요. `plot()` 함수의 `kind` 에 'bar' 를 넣어서 호출하면 그런 그래프를 그릴 수 있습니다. 그래프 제목 및 X축, Y축 이름을 지정하고 격자까지 추가해서 그래프를 그려 볼게요.

```
avg_promotion.plot(kind='bar')
plt.title('고객 세그먼트별 프로모션 참여율')
plt.xlabel('고객 세그먼트')
plt.ylabel('프로모션 참여율')
plt.grid()
```





1등급에서 3등급으로 갈수록 대체로 프로모션 참여율이 눈에 띄게 증가하는 걸 확인할 수 있네요. 특히 1등급 세그먼트 고객 중에 1번 프로모션에 참여한 사람은 아무도 없을 정도예요. 돈을 많이 쓰는 고객일수록 그만큼 평소에 마트 행사에도 관심이 많을 가능성이 커 참여율이 높아지는 게 아닐까 싶습니다. 다만 3번 프로모션은 모든 고객 세그먼트에서 비슷한 참여율을 기록했다는 점이 특이하네요.

그럼 매출 기여도가 높은 3등급 세그먼트 고객을 타겟으로 프로모션을 새롭게 진행할 때 어떤 점을 참고하면 좋을까요? 일단 2번 프로모션은 참여율이 저조했으니 문제점이 무엇이었는지 복기해 볼 수 있겠죠. 한편 1, 4, 5번 프로모션의 참여율이 준수한 편이었고 6번 프로모션의 참여율은 다른 프로모션에 비해 확실히 높았습니다. 이러한 점을 참고하여 프로모션을 기획해 보면 좋을 것 같네요.

이번 레슨은 어땠나요?



관련 질문

plt.show() 의 역할

```
for i_segment in range(1, num_grades + 1): age_group_dist = groupby_rfm_segment_age_group[
    groupby_rfm_segment_age_group['rfm_segment'] == i_segment] age_group_dist['num_customers
```

✓ 답변 1

리스트 생성 시 for/if 문 질문

첫 번째 코드는 해설에 있는 코드, 두 번째 코드는 제가 쓴 코드입니다. 1. 두 번째 방식으로 실행 시 invalid syntax 문법 오류가 나오는데 어디가 잘못된 건가요? 2. 첫 번째 해설 코드를 보면 for문과 if문 뒤에 콜론(:)이 없는데 콜론 없...

✓ 답변 1

'label' must be of length 'x' 에러

코드 두 번째부분을 실행하면 첫번째처럼 오류가 납니다. 사진 첨부합니다. 어떻게 하면 될까요?-----
----- ValueError Traceback (most recent call last

답변 1

질문 더 보기

질문하기

의견 보내기

🏠 홈으로 이동

← 07. RFM 고객 세그먼트 분류

레슨완료